synapse.ai

JEV o no JEV: Esa es la cuestión

Benchmark del modelo de decisión frente a LLM de propósito general en tres modalidades: `noul`, `choice` y `score`.

Abstract

Contexto. Los agentes que deben decidir (aprobar o rechazar, elegir una opción, asignar un puntaje) pueden resolverlo con un modelo de decisión especializado o con un LLM de propósito general con instrucciones de formato estricto. La elección afecta calidad, robustez del parseo, latencia y costo.

Objetivo. Determinar, con un benchmark propio y evaluación humana, si conviene usar JEV o un LLM general en tres modalidades de decisión: `noul` (sí/no), `choice` (opción cerrada) y `score` (puntaje numérico).

Método. Se diseñaron diversos escenarios por modalidad, ejecutados con la misma base en los cuatro modelos. Como JEV no ofrece capa de prueba, el brazo de decisión se ejecutó con un modelo de decisión sustituto y su gasto se recalculó a precio JEV (solo tokens de entrada). Antes del análisis se eliminó un quinto modelo por tiempos de otro orden, se quitaron los casos sin cobertura completa y los casos con fallas transitorias, de modo de comparar exactamente los mismos casos en todos. Ningún modelo recibió fine-tuning ni ajuste de hiperparámetros. Cada respuesta fue evaluada por un humano (acierto, puntaje de referencia y marca de texto adicional fuera de formato). El análisis final cubre 41 casos balanceados (17 `noul`, 10 `choice`, 14 `score`) por 4 modelos.

Resultados. En `noul`, `gpt-oss-20b` logra accuracy 0,941 frente a 0,882 de los otros tres. En `choice`, `gemini` y `gpt-oss-20b` alcanzan 1,0 frente a 0,9 del modelo de decisión y de `qwen`. En `score`, el modelo de decisión obtiene el menor error absoluto medio (0,29) frente a 0,38–0,46 de los generales. El error de parseo (texto adicional fuera del formato estricto, medido solo en los LLM generales) es mayor en `noul` para `gpt-oss-20b` (0,647) y en `choice` para `gemini` (0,30), y nulo en `score`. En latencia dentro de cada tarea, `qwen` y `gpt-oss-20b` presentan las medias y medianas más bajas. En gasto por llamada, el modelo de decisión a precio JEV es el menor en las tres modalidades.

Conclusión. JEV domina en costo en las tres modalidades, en calibración numérica (`score`) y en salida estructurada sin texto adicional, con accuracy competitiva en `noul` y `choice`. Los LLM generales lo igualan o superan en accuracy puntual según la modalidad y responden más rápido en media, a cambio de mayor costo y mayor frecuencia de texto fuera de formato cuando se exige salida estricta.

Palabras clave: evaluación de modelos, decisión estructurada, noul, choice, score, evaluación humana, latencia, costo, error de parseo.

---

1. Introducción

La pregunta que organiza este trabajo es si conviene usar un modelo de decisión especializado (JEV) o resolver las decisiones con un LLM de propósito general. Para responderla se armó un benchmark propio con diversos escenarios para cada modalidad, se ejecutaron los cuatro modelos sobre los mismos casos y se evaluó con criterio humano cada respuesta.

Modelos evaluados:

- `inception/mercury-decide:free`: modelo de decisión, sustituto técnico de JEV.
- `gemini-3.5-flash-lite`.
- `openai/gpt-oss-20b`.
- `qwen/qwen3.8-27b`.

Modalidades:

- `noul`: pregunta de sí/no.
- `choice`: elección de una opción dentro de un listado cerrado.
- `score`: asignación de un puntaje numérico en una escala definida por niveles.

---

2. Metodología



2.1. Diseño de escenarios

Se usaron diversos escenarios para cada modalidad. Todos los modelos recibieron la misma base y solo se agregó la instrucción de tarea correspondiente a la modalidad: en `choice`, elegir una de las opciones y devolver solo la opción; en `score`, devolver solo el número en la misma escala del modelo de decisión (puede caer entre niveles); en `noul`, responder solo la pregunta. En los tres casos se ordena no agregar texto extra y no argumentar.

2.2. Ejecución y sustituto de JEV

Como JEV no ofrece capa de prueba, la ejecución del brazo de decisión se hizo con un modelo de decisión sustituto, y el gasto de ese brazo se calculó con el precio de JEV (USD 0,042 por millón de tokens de entrada). JEV no cobra tokens de salida, por lo que el cálculo usa solo los tokens de entrada. Los gastos de los otros tres modelos son los reportados por cada proveedor en la corrida. Solo el modelo de decisión informa confianza; en los LLM comparados es nula por diseño. Ninguno de los modelos fue sometido a fine-tuning ni a ajuste de hiperparámetros; todos se evaluaron en su configuración por defecto tal como los expone cada proveedor.

2.3. Limpieza

Las decisiones de limpieza fueron:

1. **Se excluyó un quinto modelo.** Sus tiempos eran de un orden muy distinto al resto (media de 10,80 s frente a 0,6–2,0 s de los demás) y rompían la comparación.
2. **Se quitaron los primeros casos para todos los modelos.** Un modelo no participó en esos casos iniciales, por lo que se quitaron para mantener comparación exacta (mismos casos en todos).
3. **Se quitaron los casos en los que un modelo falló.** Hubo fallas transitorias de límite de tasa en un modelo. Para no sesgar los promedios, se borraron esos casos completos para todos los modelos, de modo de comparar en todos lo mismo.

El análisis final cubre **41 casos por 4 modelos**, balanceados: 17 `noul`, 10 `choice` y 14 `score`.

2.4. Evaluación humana

Cada respuesta fue revisada por un humano según tres criterios:

- **`noul` y `choice`:** acierto según criterio humano. Se evalúa accuracy (proporción de aciertos).
- **`score`:** puntaje de referencia asignado por el humano con los mismos parámetros del LLM (misma escala). Se evalúa el error absoluto medio entre la decisión numérica del modelo y la referencia humana.
- **Error de parseo:** marca cuando la respuesta trae texto adicional que impide el parseo estricto, aunque el contenido sea correcto. **En error de parseo nunca se cuenta el modelo de decisión, porque no da texto** (devuelve respuesta estructurada); la métrica se calcula solo sobre los LLM comparados.

2.5. Métricas

- Distribución de tokens de entrada y de tiempo por tarea y por modelo.
- Tiempo por modelo dentro de cada tarea.
- Tiempo por modelo por cuartil de tokens de entrada (sirve para comparar rendimiento frente a tokens de entrada).
- Gasto por modelo dentro de cada tarea.
- Accuracy por modelo en `noul` y `choice`, más tasa de error de parseo (sin el modelo de decisión).
- Error absoluto medio por modelo en `score`, más tasa de error de parseo (sin el modelo de decisión).

Todas las comparaciones de tiempo son dentro de cada tarea o por cuartil de entrada.

Aclaración sobre los tokens de salida: en `openai/gpt-oss-20b` se observan conteos altos (media 284, mediana 202, máximo 1224, frente a 1–3 en los demás). Ese conteo corresponde al razonamiento interno incluido en el uso reportado, no a texto emitido en la respuesta. Por eso hay muchos casos con conteo alto y sin marca de error de parseo. Ese conteo sí se computa para el gasto, pero no significa que el modelo haya devuelto ese texto.

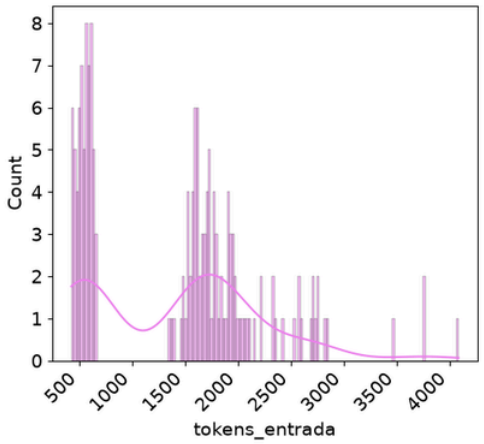
---

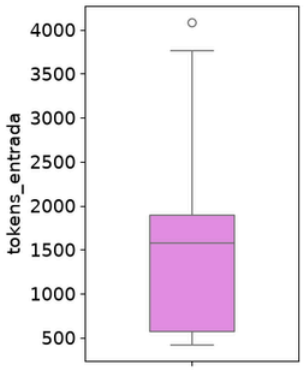
3. Resultados

3.1. Tokens de entrada

Los tokens de entrada van de 420 a 4083 (media 1405, Q1 578, mediana 1584,5, Q3 1892,25).

Figura 1. Distribución general de tokens de entrada (todas las evaluaciones, histograma, boxplot y estadísticos).



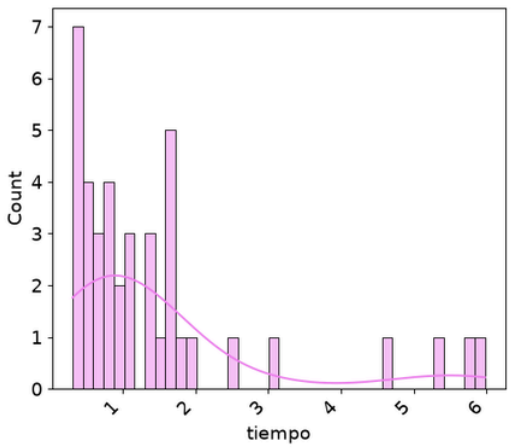


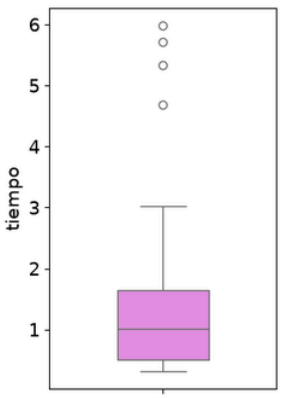
Min: 420.0000
Max: 4083.0000
Q1: 578.0000
Q2: 1584.5000
Q3: 1892.2500
Q4: 4083.0000
Mean: 1405.2378
Median: 1584.5000
Mode: 614.0000
Std: 804.4179
IQR: 1314.2500
Top Limit Outliers: 3863.6250
Bottom Limit Outliers: N/A
Total Data: 164
Outliers Quantity: 1 (0.61)%

3.2. Tiempo por tarea y por modelo

Las Figuras 2 a 4 muestran la distribución del tiempo de respuesta agrupando por modalidad (todos los modelos juntos); las Figuras 5 a 8 la muestran agrupando por modelo (todas las modalidades juntas). Cada figura incluye histograma, boxplot y estadísticos.

Figura 2. Distribución del tiempo de respuesta en la modalidad `choice`.





Min: 0.3100
Max: 5.9800
Q1: 0.5125
Q2: 1.0150
Q3: 1.6375
Q4: 5.9800
Mean: 1.4872
Median: 1.0150
Mode: 0.7700
Std: 1.4557
IQR: 1.1250
Top Limit Outliers: 3.3250
Bottom Limit Outliers: N/A
Total Data: 40
Outliers Quantity: 4 (10.0)%

Figura 3. Distribución del tiempo de respuesta en la modalidad `score`.

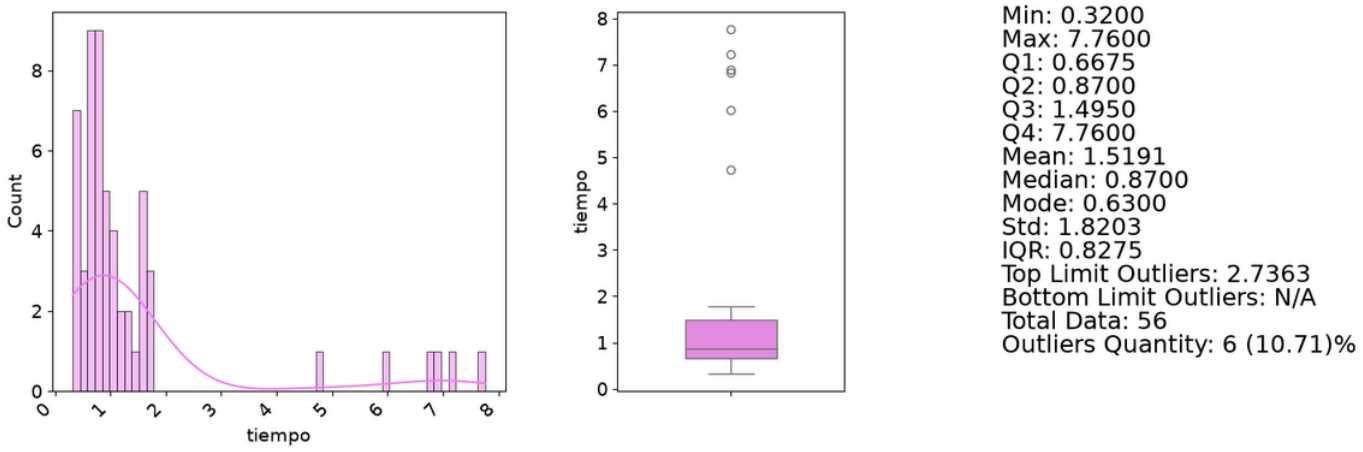


Figura 4. Distribución del tiempo de respuesta en la modalidad `noul` .

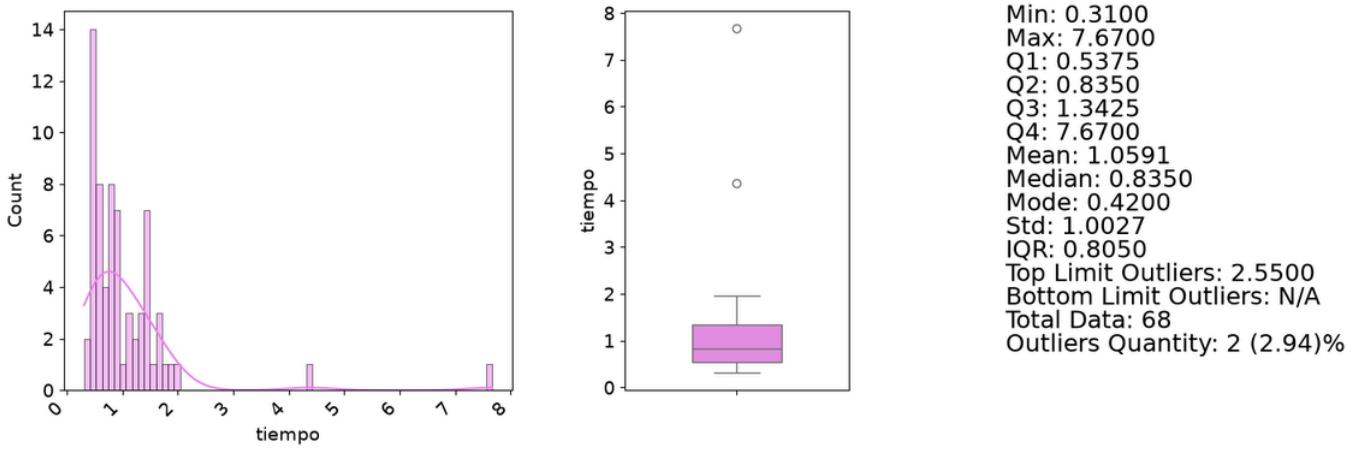


Figura 5. Distribución del tiempo de respuesta del modelo de decisión (todas las modalidades).

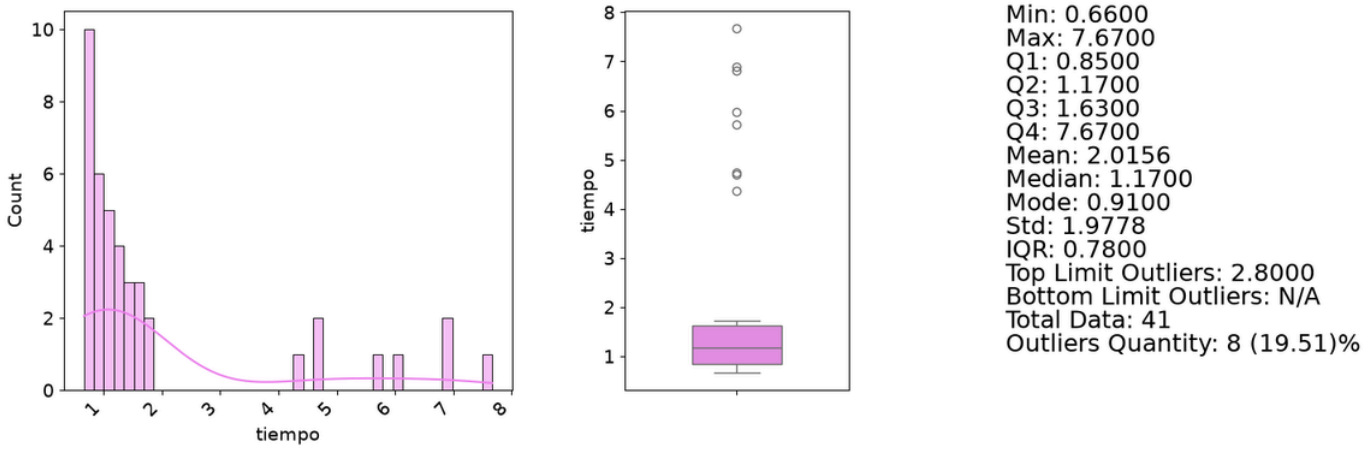


Figura 6. Distribución del tiempo de respuesta de `gemini` (todas las modalidades).

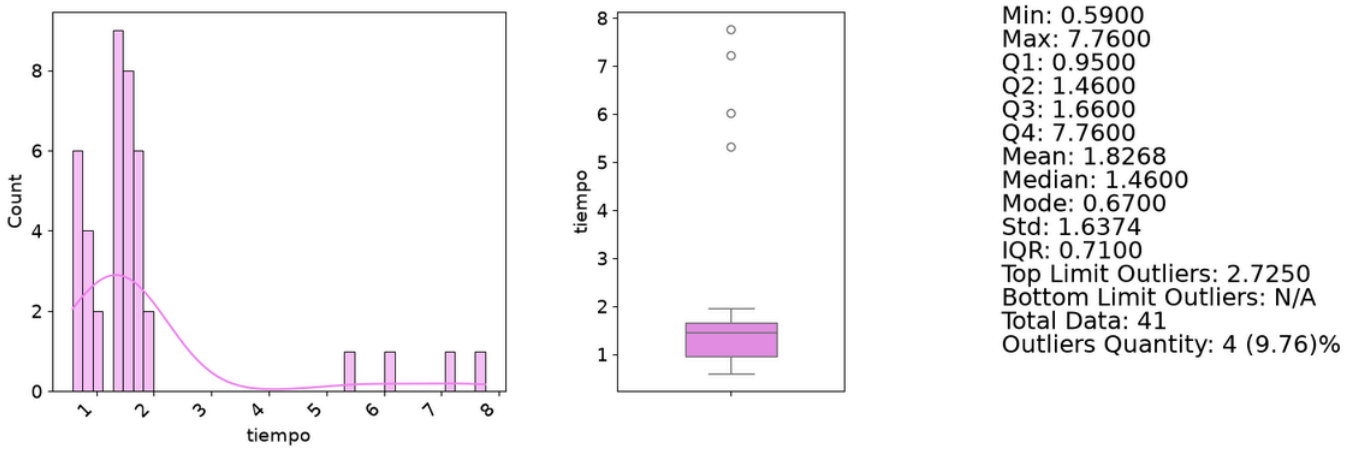


Figura 7. Distribución del tiempo de respuesta de `gpt-oss-20b` (todas las modalidades).

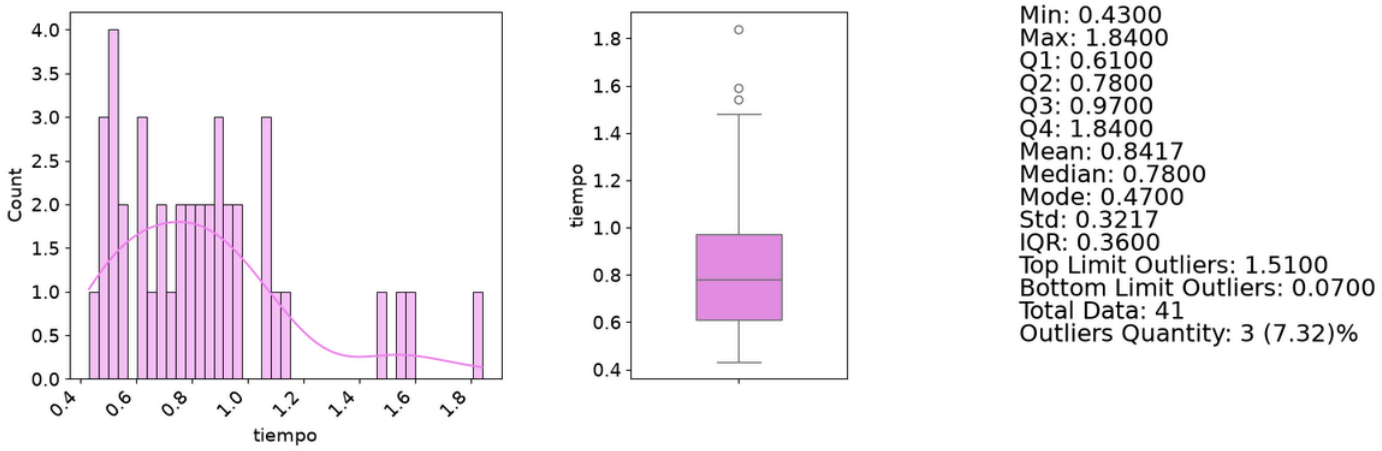
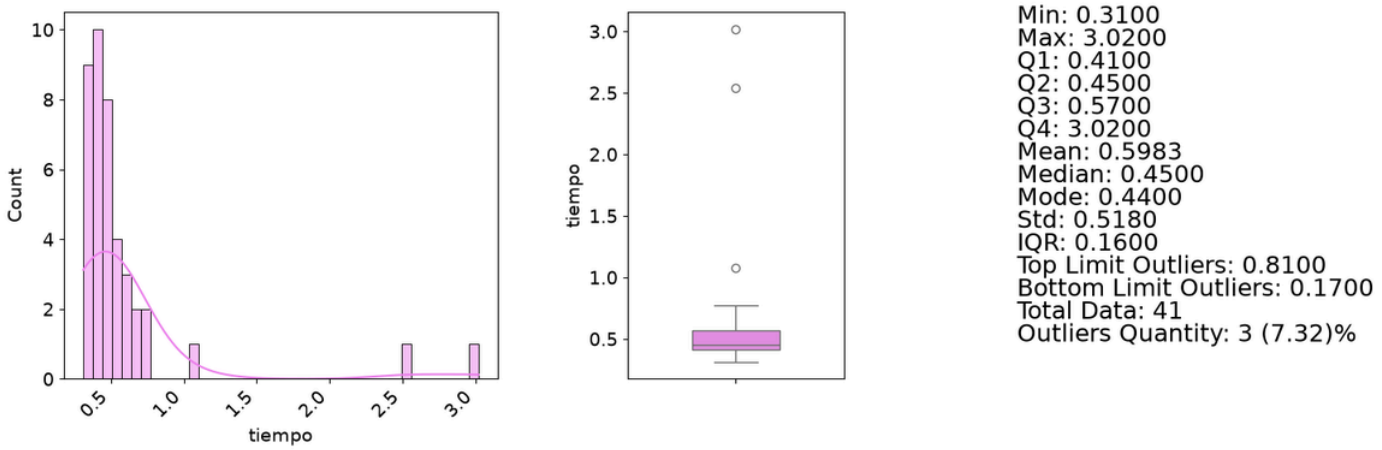


Figura 8. Distribución del tiempo de respuesta de `qwen` (todas las modalidades).



Medias de tiempo: `qwen` 0,60 s (mediana 0,45), `gpt-oss-20b` 0,84 s (mediana 0,78), `gemini` 1,83 s (mediana 1,46), modelo de decisión 2,02 s (mediana 1,17); máximos 3,02, 1,84, 7,76 y 7,67 s respectivamente; mínimos 0,31–0,66 s.

3.3. Tiempo por modelo dentro de cada tarea

Figura 9. Tiempo mínimo, medio y máximo por modelo en la modalidad `noul`.

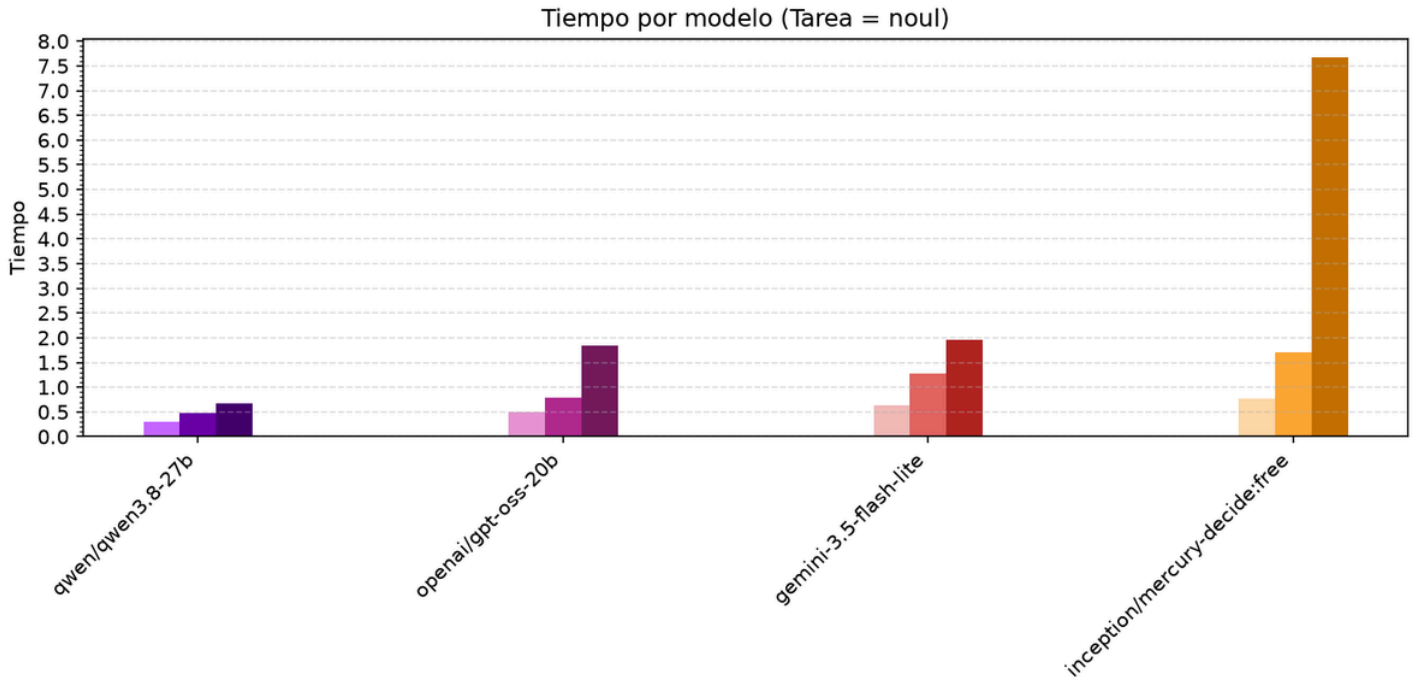


Figura 10. Tiempo mínimo, medio y máximo por modelo en la modalidad `score`.

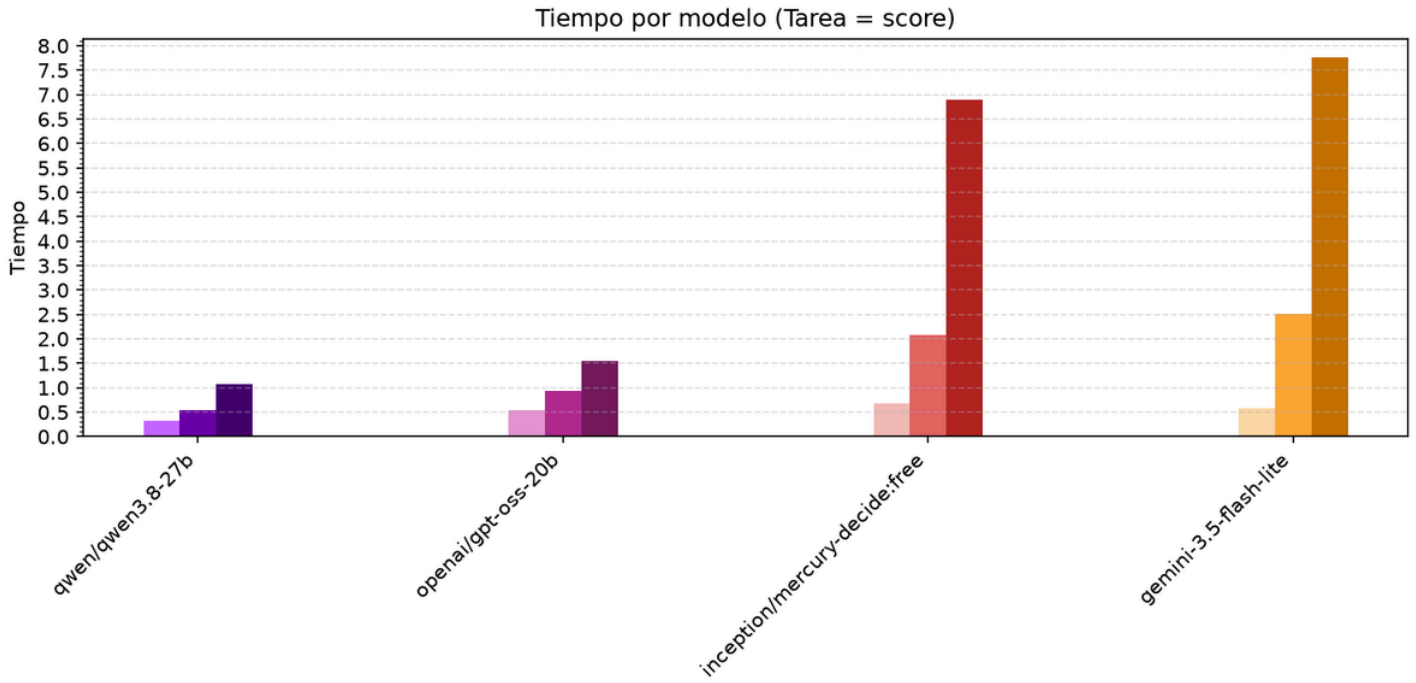
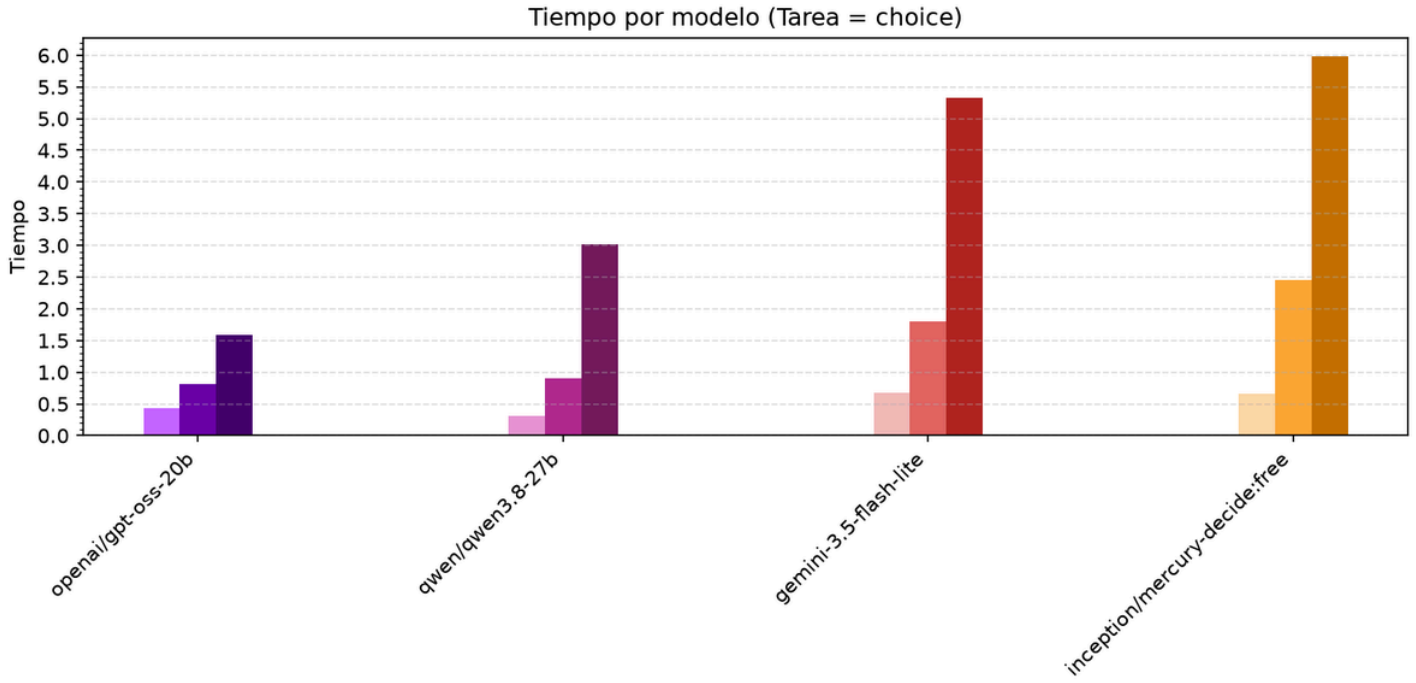


Figura 11. Tiempo mínimo, medio y máximo por modelo en la modalidad `choice`.



Dentro de cada tarea (`noul` , `score` , `choice`), `qwen` y `gpt-oss-20b` presentan las medias más bajas y el modelo de decisión y `gemini` las más altas, con máximos más elevados en estos dos últimos. Cada grupo está ordenado por media.

3.4. Tiempo por modelo por cuartil de tokens de entrada

Cuatro grupos por cuartil de tokens de entrada (Q1 420–578, Q2 578–1584, Q3 1584–1892, Q4 1892–4083, aprox.). Permite comparar rendimiento frente a tokens de entrada controlando el tamaño de la base.

Figura 12. Tiempo mínimo, medio y máximo por modelo en el cuartil Q1 de tokens de entrada.

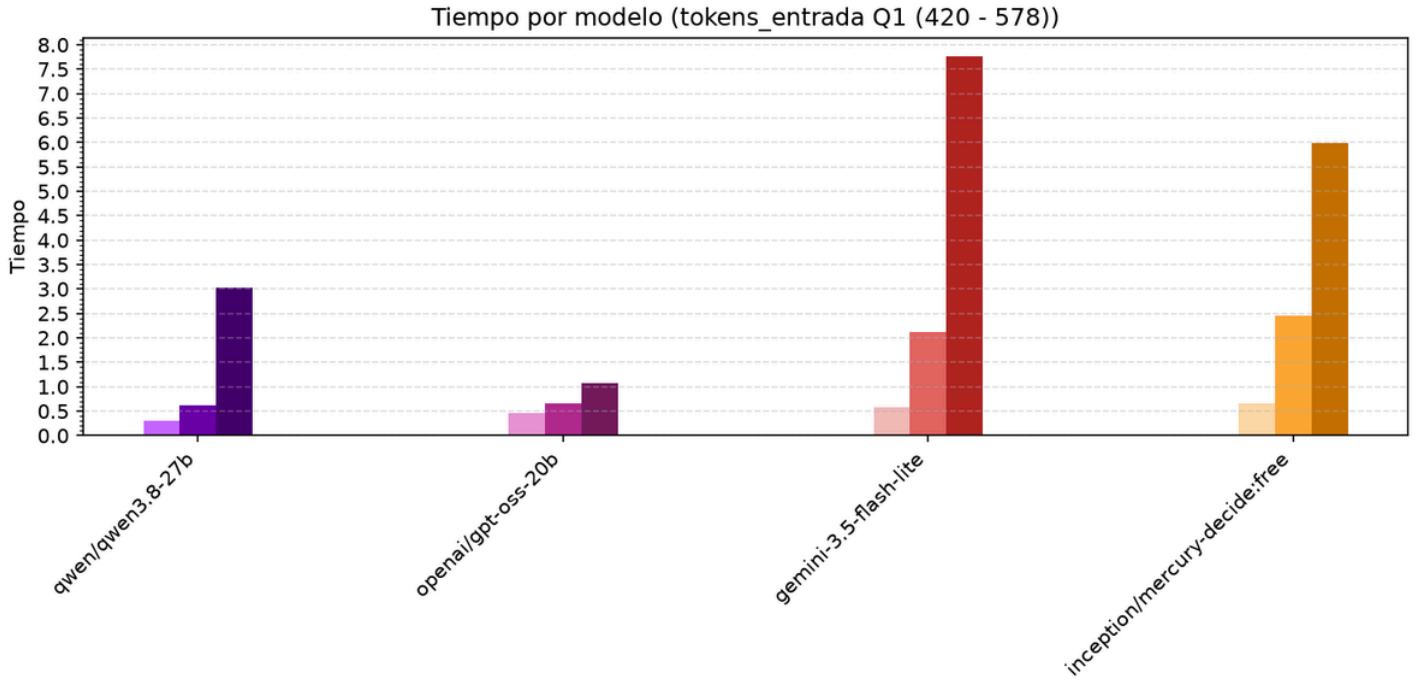


Figura 13. Tiempo mínimo, medio y máximo por modelo en el cuartil Q2 de tokens de entrada.

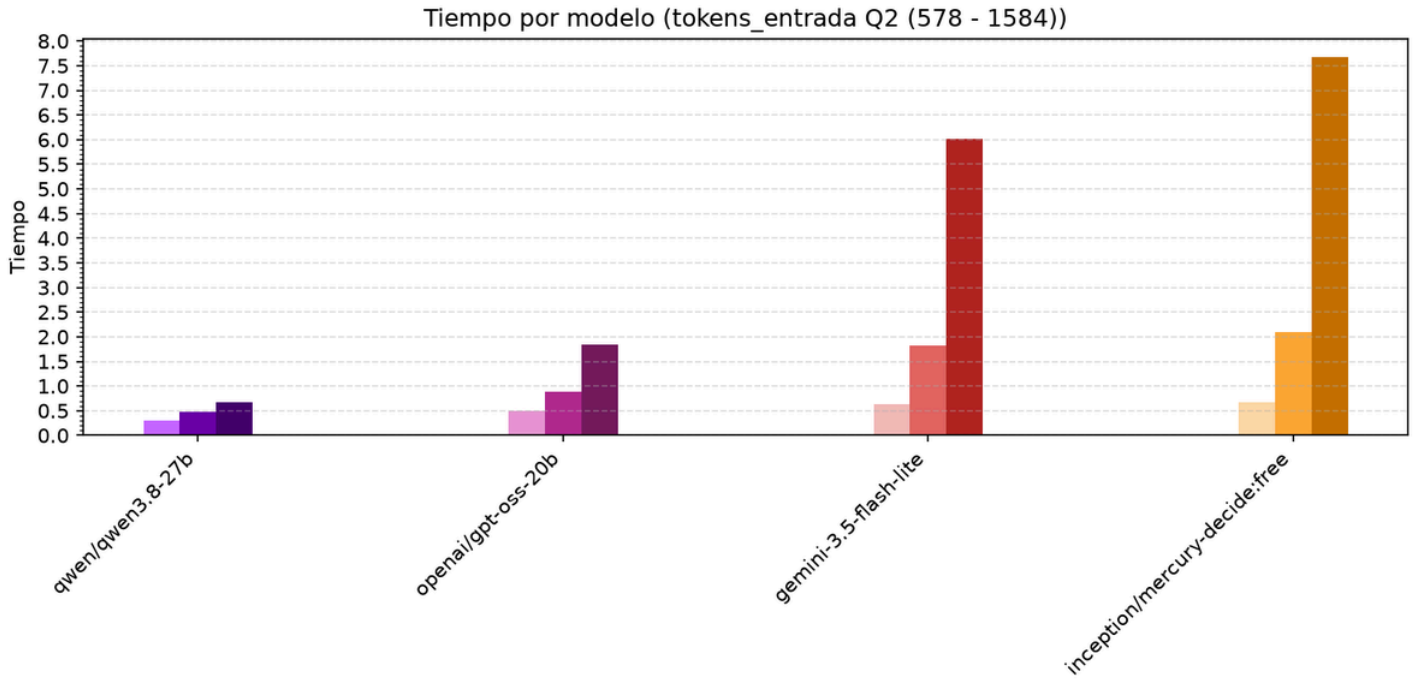


Figura 14. Tiempo mínimo, medio y máximo por modelo en el cuartil Q3 de tokens de entrada.

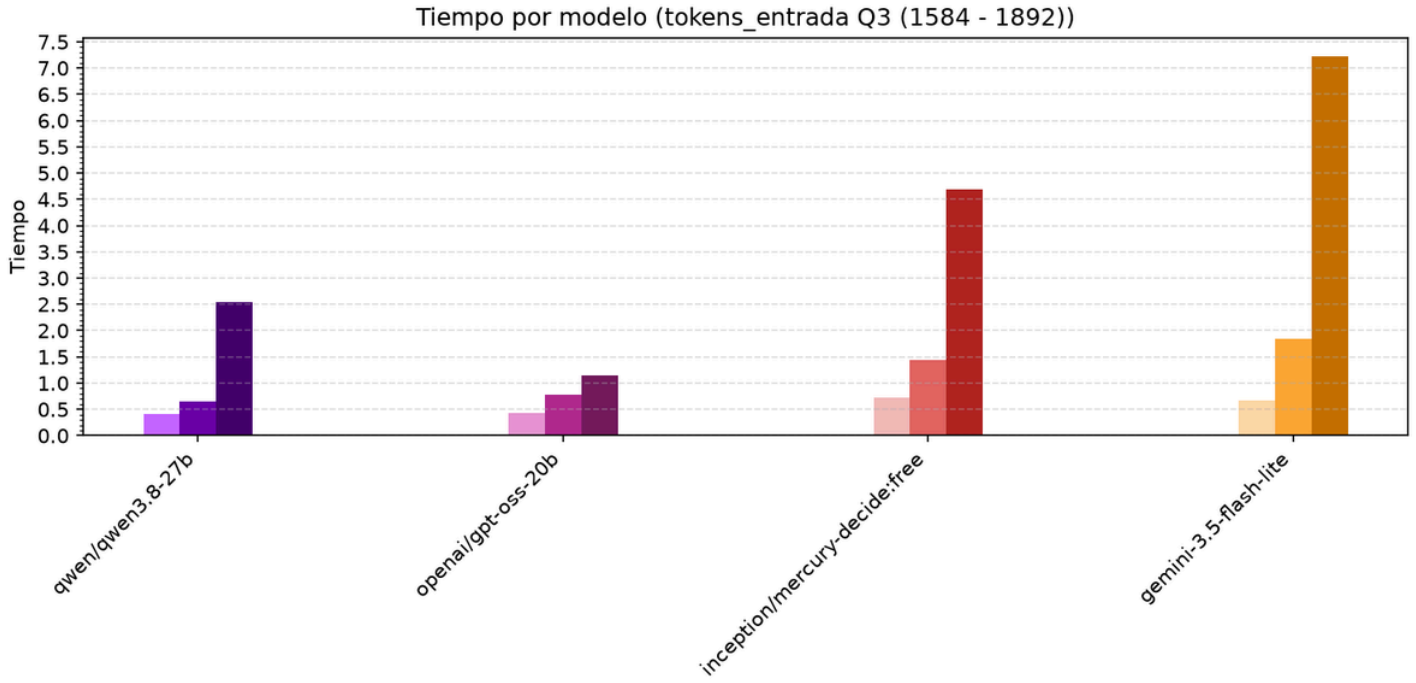
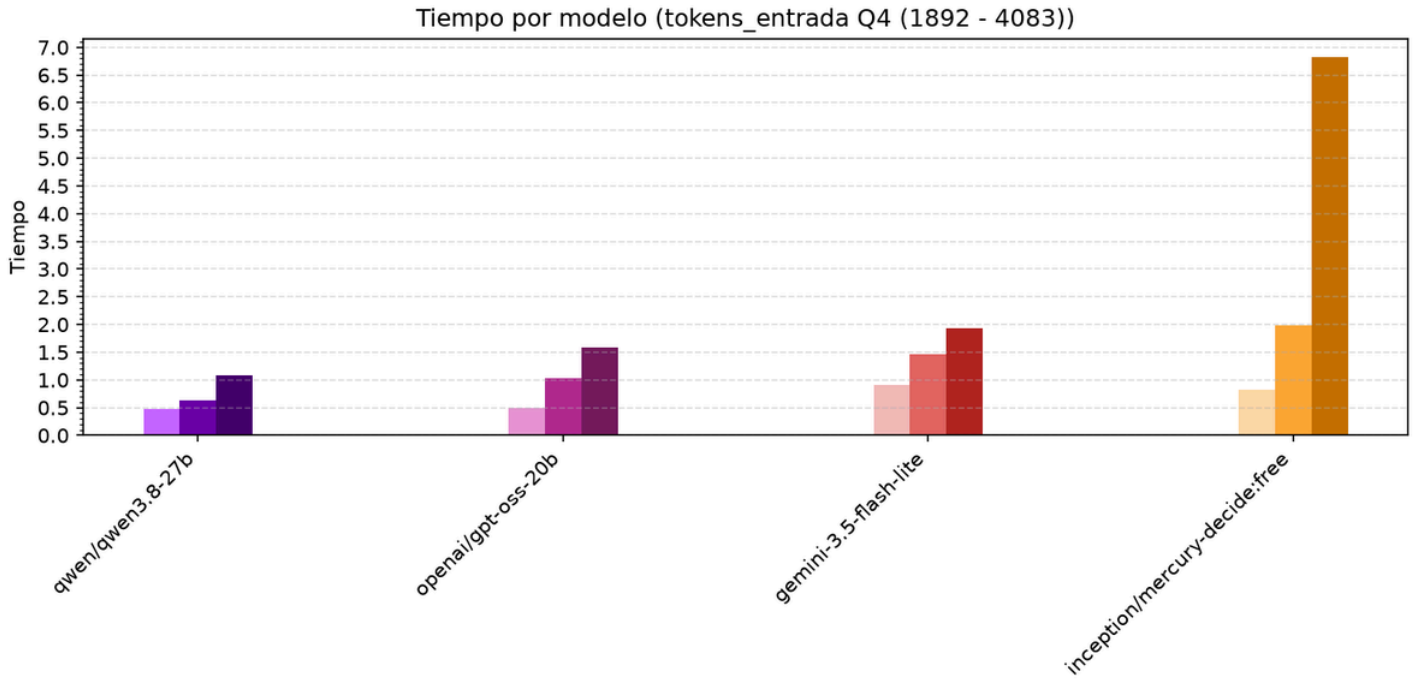


Figura 15. Tiempo mínimo, medio y máximo por modelo en el cuartil Q4 de tokens de entrada.



3.5. Accuracy en `noul` y `choice`

`noul` (n = 17 por modelo): `openai/gpt-oss-20b` 0,941 (16/17); modelo de decisión, `gemini-3.5-flash-lite` y `qwen/qwen3.8-27b` 0,882 (15/17). Los cuatro modelos fallan en un mismo caso; además cada uno falla en un caso distinto.

`choice` (n = 10 por modelo): `gemini-3.5-flash-lite` y `openai/gpt-oss-20b` 1,0 (10/10); modelo de decisión 0,9 y `qwen/qwen3.8-27b` 0,9 (un fallo cada uno, en casos distintos).

Figura 16. Accuracy por modelo en `noul`.

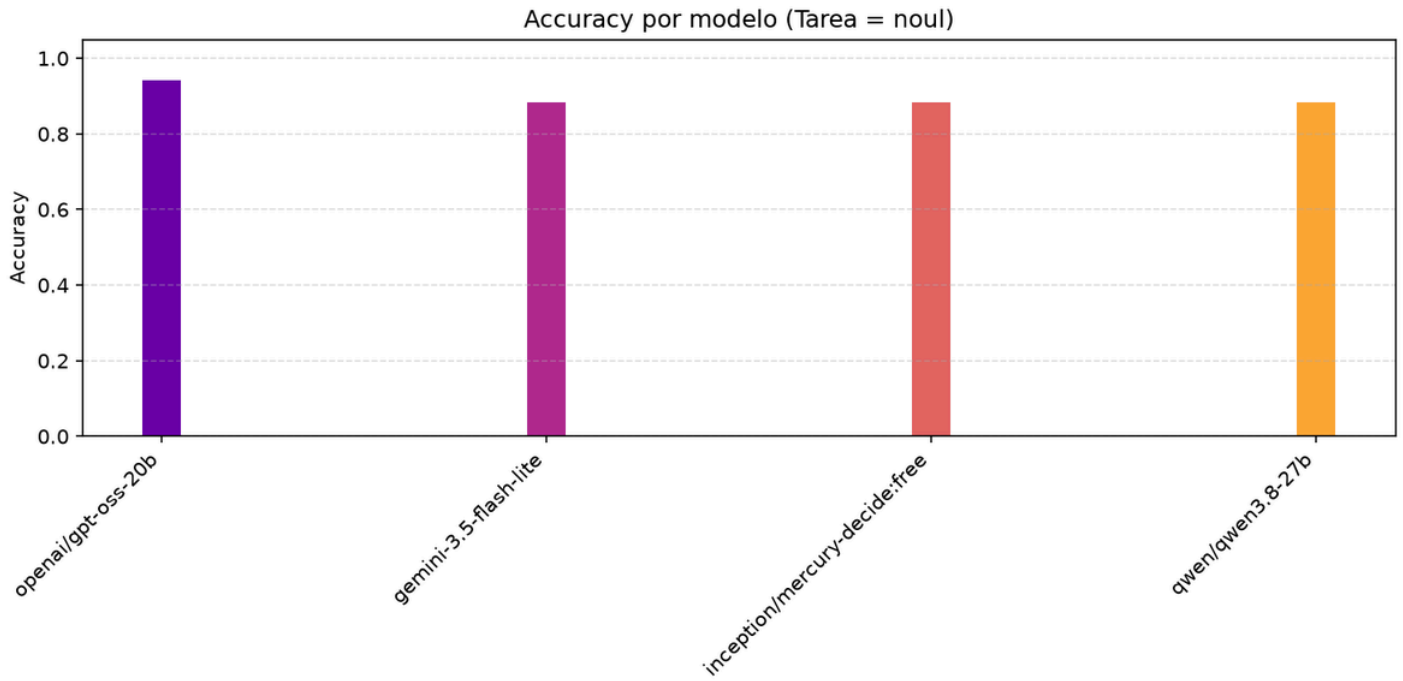


Figura 17. Tasa de error de parseo en `noul` sin el modelo de decisión.

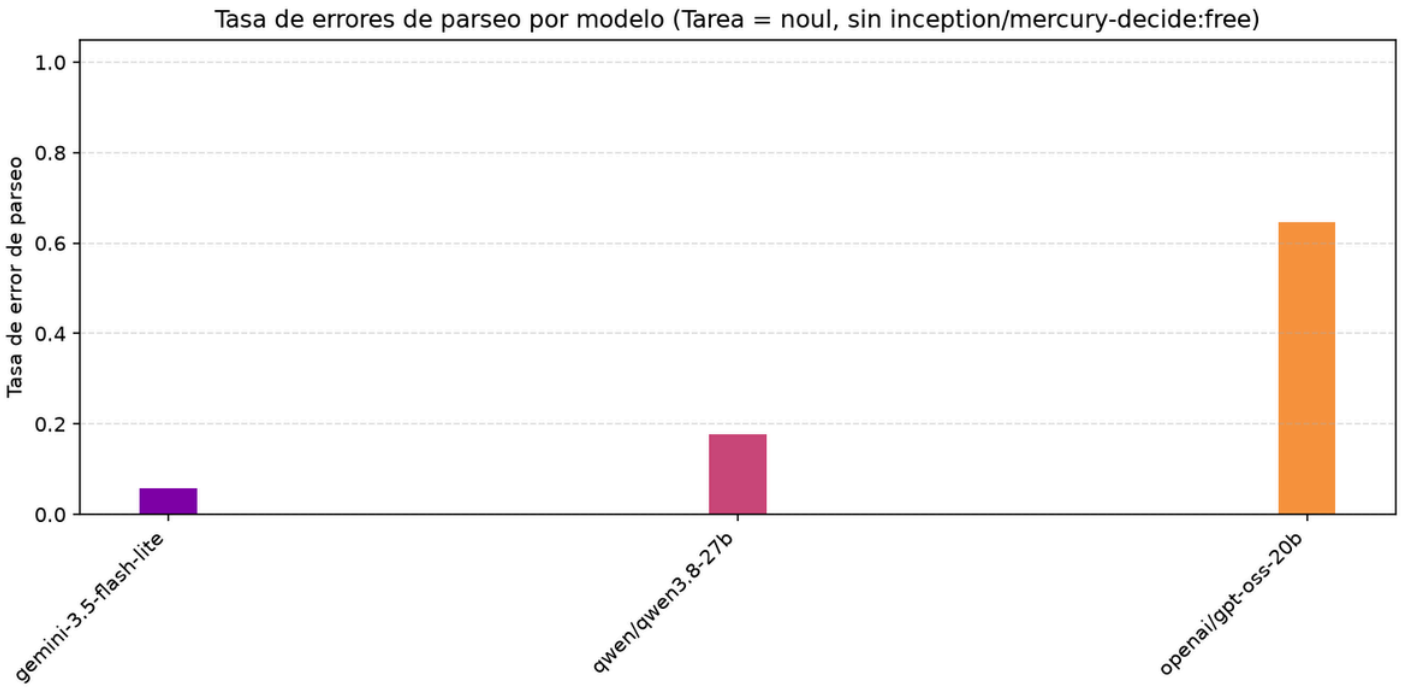


Figura 18. Accuracy por modelo en `choice`.

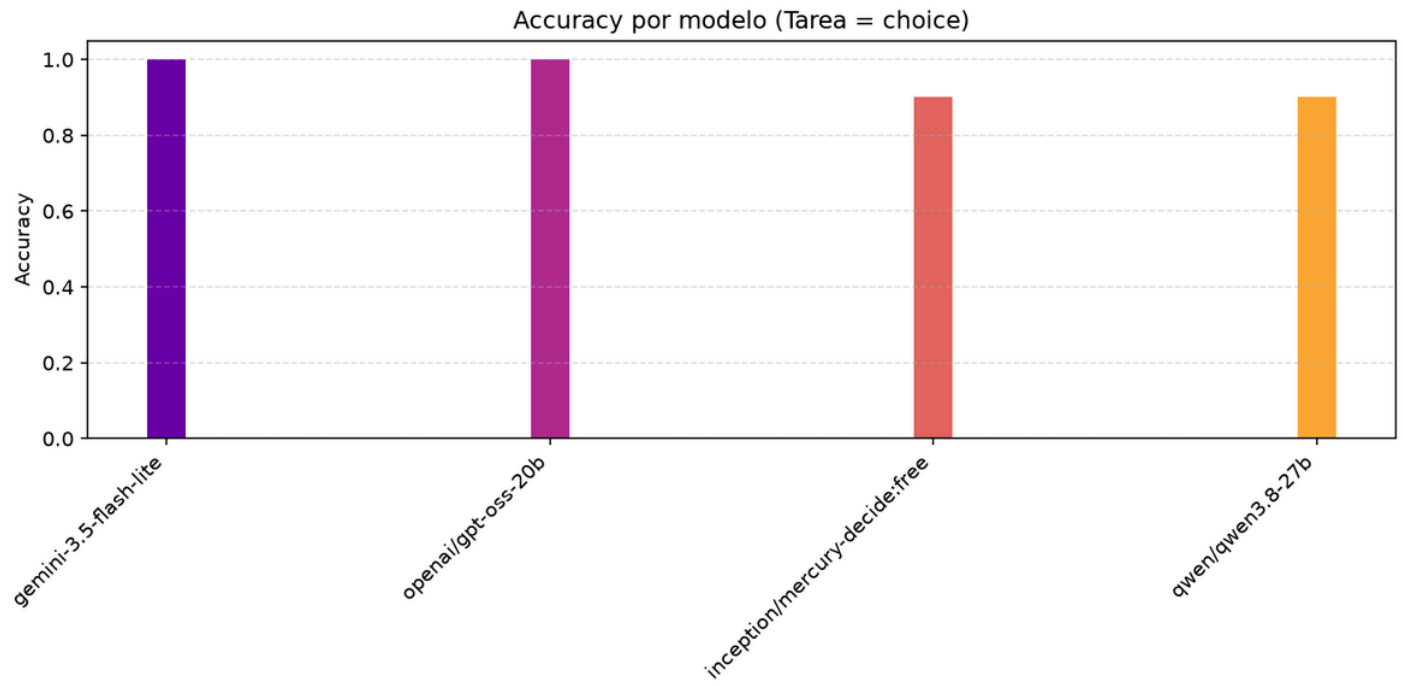
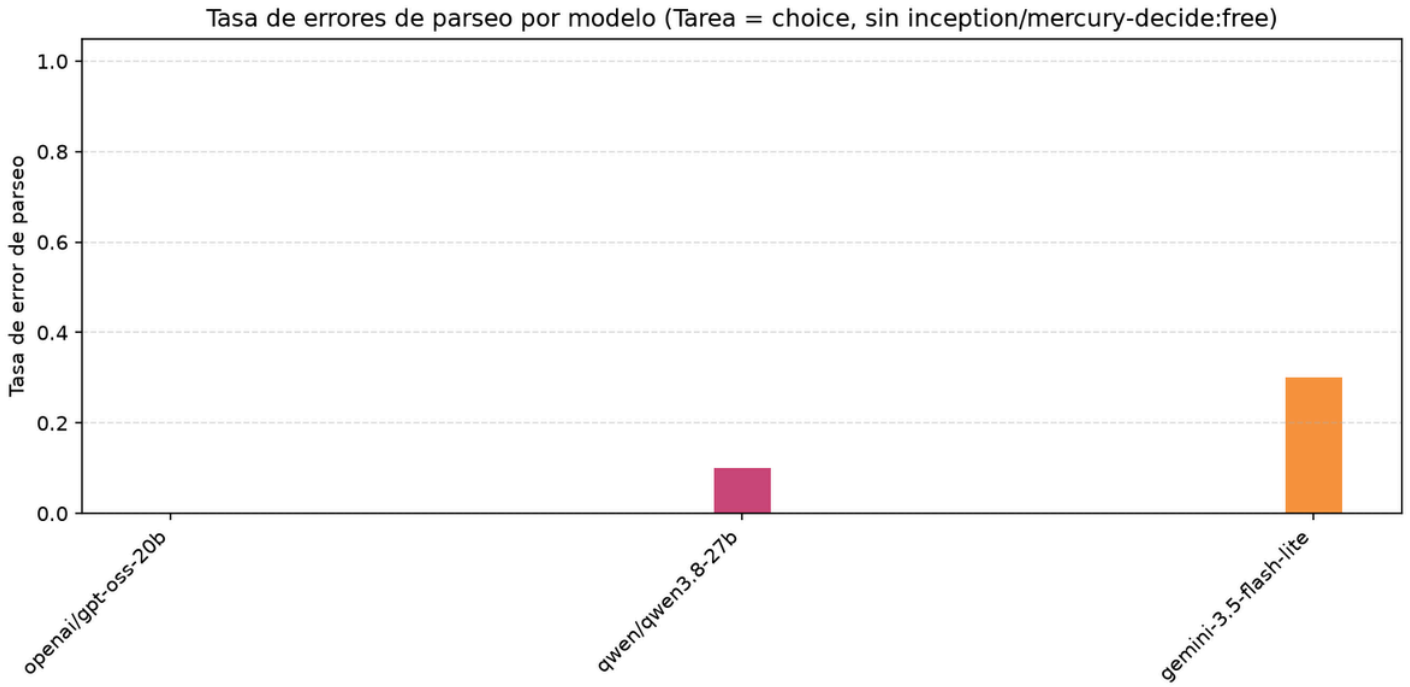


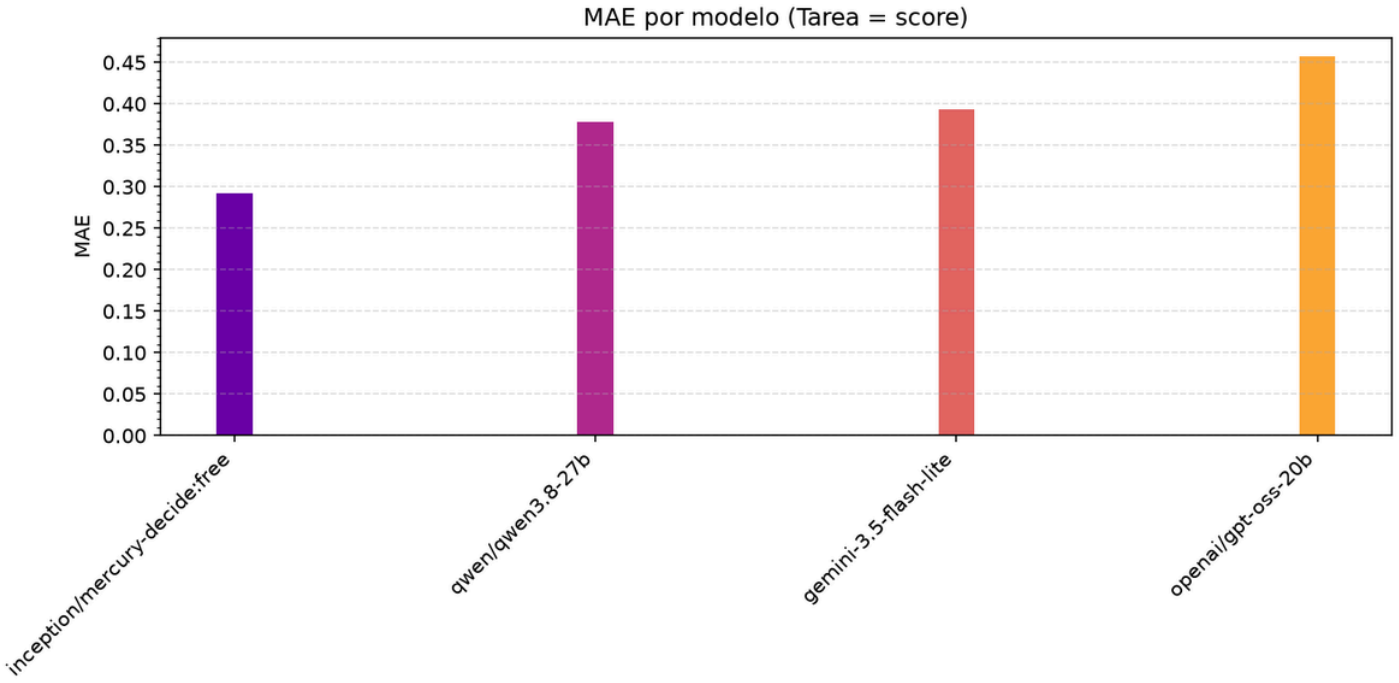
Figura 19. Tasa de error de parseo en `choice` sin el modelo de decisión.



3.6. Error absoluto medio en `score`

`score` (n = 14 por modelo; menor es mejor): modelo de decisión 0,29 (mediana 0,235, máximo 0,87); `qwen/qwen3.8-27b` 0,38 (mediana 0,20, máximo 2,00); `gemini-3.5-flash-lite` 0,39 (mediana 0,40, máximo 1,20); `openai/gpt-oss-20b` 0,46 (mediana 0,40, máximo 1,00).

Figura 20. Error absoluto medio por modelo en `score`.



3.7. Tasa de error de parseo

Calculada solo sobre los LLM comparados (el modelo de decisión no emite texto libre y no entra en esta métrica):

- `noul` : `gpt-oss-20b` 0,647 (11/17), `qwen` 0,176 (3/17), `gemini` 0,059 (1/17).
- `choice` : `gemini` 0,30 (3/10), `qwen` 0,10 (1/10), `gpt-oss-20b` 0,0.
- `score` : 0,0 en los tres LLM comparados.

Las respuestas con texto adicional se evaluaron como correctas o incorrectas según contenido, y además se marcaron con error de parseo.

3.8. Gasto por modelo dentro de cada tarea

Gasto en USD por llamada, con el brazo de decisión valuado a precio JEV (solo tokens de entrada).

Figura 21. Gasto mínimo, medio y máximo por modelo en la modalidad `noul` .

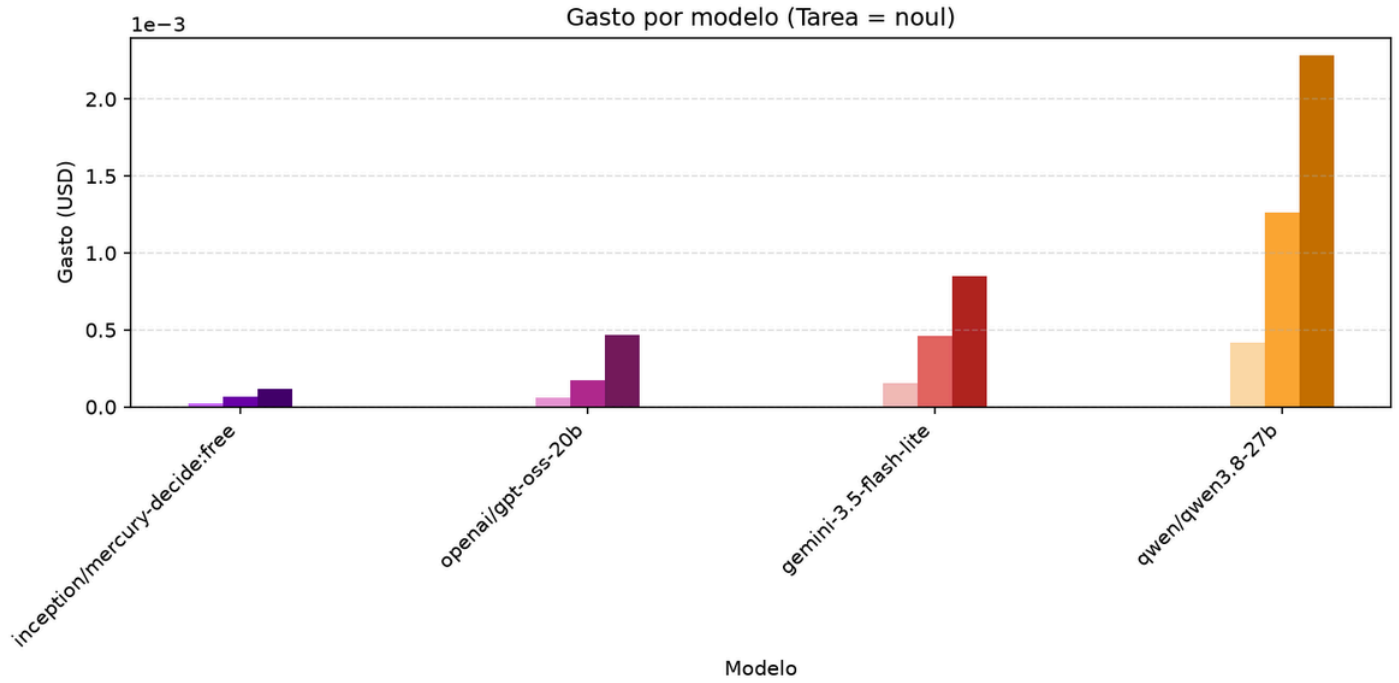


Figura 22. Gasto mínimo, medio y máximo por modelo en la modalidad `score`.

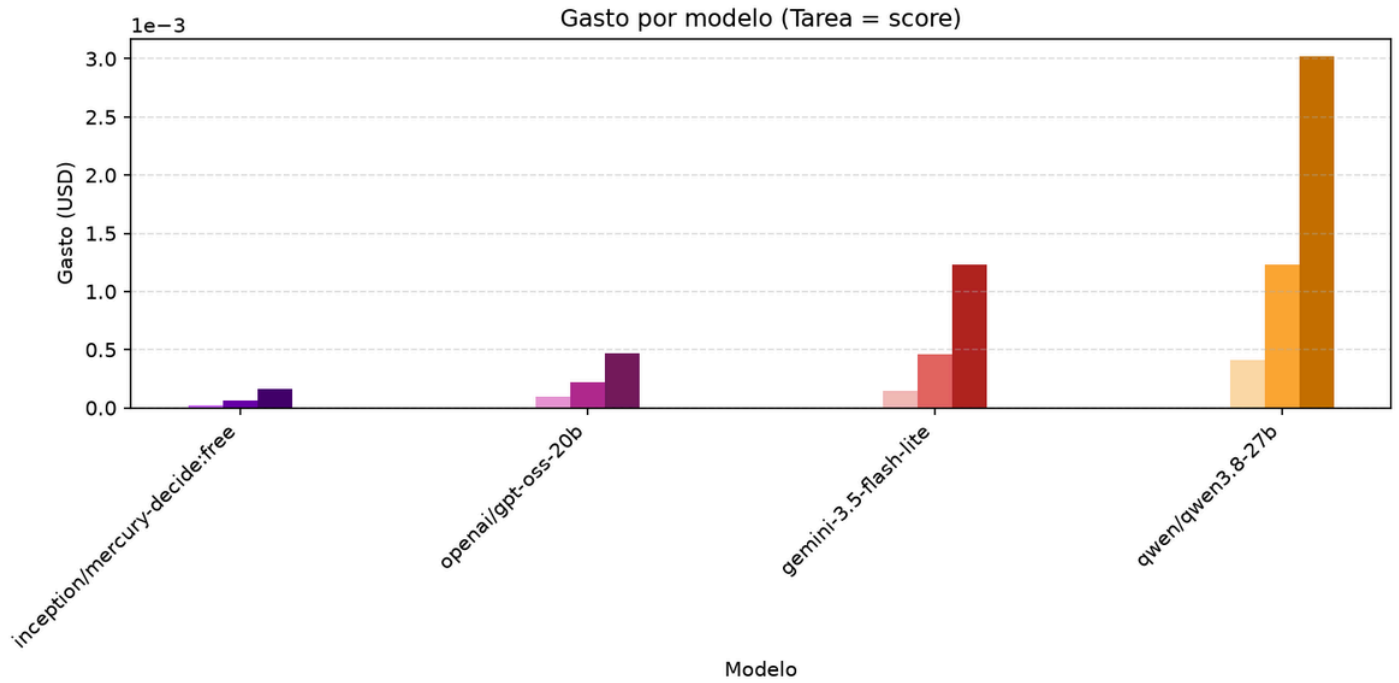
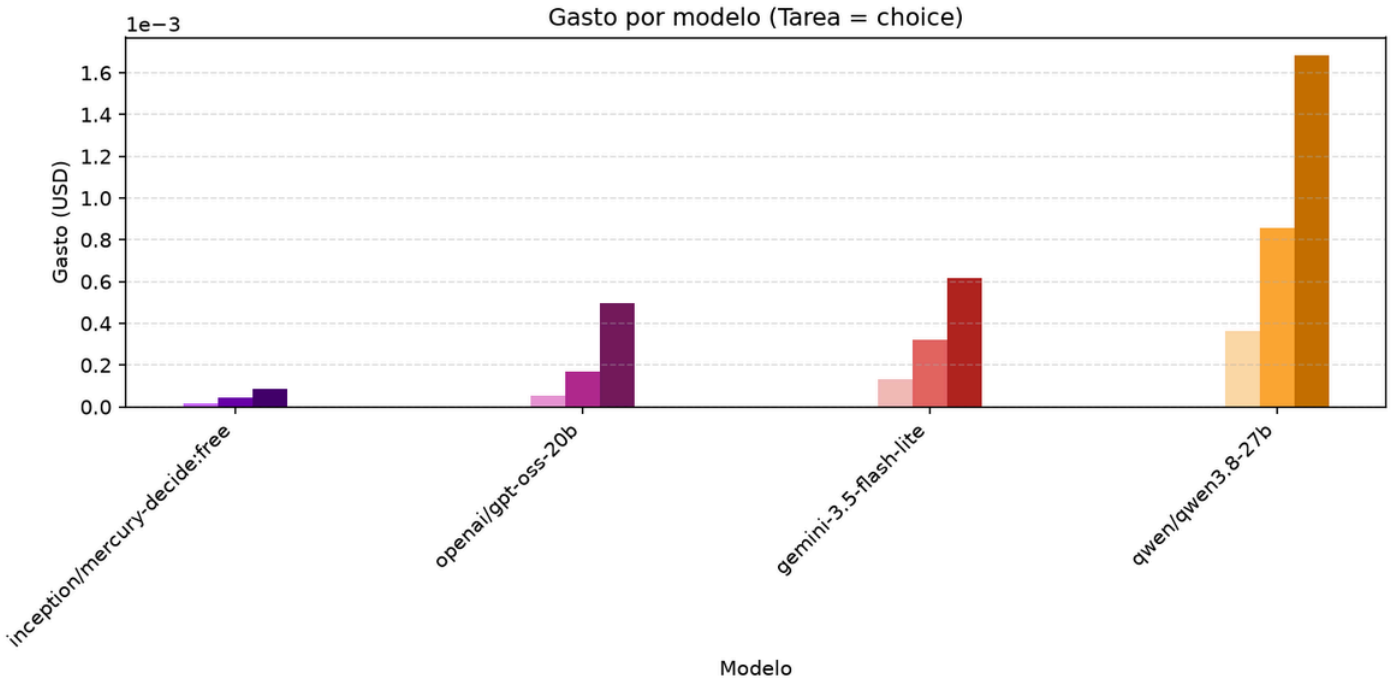


Figura 23. Gasto mínimo, medio y máximo por modelo en la modalidad `choice`.

synapse.ai



Totales sobre los 41 casos: modelo de decisión a precio JEV USD 0,002423; `gpt-oss-20b` USD 0,007757; `gemini` USD 0,017539; `qwen` USD 0,047310. Medias por llamada: JEV 0,000059; `gpt-oss-20b` 0,000189; `gemini` 0,000428; `qwen` 0,001154. El orden se mantiene en las tres modalidades (`noul` , `score` , `choice`).

---

4. Discusión

El modelo de decisión obtiene el menor error absoluto medio en `score` y empata en el segundo lugar en `noul` y `choice` , con el menor gasto en las tres modalidades valuado a precio JEV. Los LLM comparados lo igualan o superan en accuracy puntual (`gpt-oss-20b` en `noul` ; `gpt-oss-20b` y `gemini` en `choice`), pero con mayor tasa de error de parseo en `noul` (`gpt-oss-20b`) y en `choice` (`gemini`). En latencia dentro de cada tarea y por cuartil de entrada, `qwen` y `gpt-oss-20b` son los más rápidos en media y mediana. El conteo alto de tokens de salida en `gpt-oss-20b` corresponde al razonamiento interno incluido en el uso reportado y computa para el gasto, sin implicar texto adicional en la respuesta.

---

5. Limitaciones

Tamaños muestrales chicos por modalidad (17 `noul` , 10 `choice` , 14 `score` por modelo); los resultados deben leerse como evidencia de este benchmark y no como generalización. El brazo JEV se evaluó técnicamente con un modelo sustituto y costo recalculado a precio JEV. Se excluyó un modelo por tiempos de otro orden y se eliminaron casos con fallas para igualar la comparación. La evaluación humana aplica un único criterio.

---

6. Conclusión

¿JEV o no JEV? Con este benchmark: JEV (vía su sustituto valuado a su precio) es la opción de menor costo en las tres modalidades, con la mejor calibración numérica en `score` y accuracy competitiva en `noul` y `choice` , sin errores de parseo por diseño. Los LLM generales son alternativas válidas según la modalidad, con mejor latencia media en `qwen` / `gpt-oss-20b` y accuracy de 1,0 en `choice` para `gemini` / `gpt-oss-20b` , a cambio de mayor gasto y, en `noul` / `choice` , mayor tasa de texto adicional fuera del formato estricto.
